

OCR 기반 채점은 이미지 생성 평가에서 렌더링 실패를 은폐한다: 한글 사례 연구

측정 타당성 연구

Taewoo Lim · 2026-08 · Technical Note (한글 번역본)

이 문서는 [TECHNICAL NOTE.md](#) (영문 원본)의 번역이다. 인용·배포할 때는 영문 원본을 정본으로 삼고, 이 번역본은 참고용으로만 쓴다. 모든 수치는 `python scripts/verify_claims.py` 로 원본 데이터에서 다시 계산할 수 있다.

초록

텍스트-이미지(T2I) 생성 모델의 시각 텍스트 렌더링 벤치마크는 대개 OCR 엔진으로 생성 이미지를 채점한다. 그런데 이 방식에는 구조적인 결함이 있다. 인식 기반 판정자는 정해진 문자 집합 안에서 반드시 하나를 골라 답해야 하는 폐쇄형 분류이기 때문에, 가장 중요한 실패 유형 — 모델이 애초에 해당 문자 체계에 존재하지 않는 글리프를 그렸다는 사실 — 자체를 보고할 방법이 없다.

상용 T2I 모델이 만든 한글 음절 이미지 300장을 감사자 두 명이 전수 검토해(이진 유효성 판정, Krippendorff's $\alpha = 0.942$) 라벨을 붙인 결과, **출력의 21.7%는 유효한 한글 음절이 아니었다**. 키보드로는 입력조차 할 수 없는, 한글처럼 생긴 글리프였다(예: 종성 ㅁ 안에 십자획이 그려진 경우). 아키텍처가 서로 다른 OCR 엔진 세 개(Naver CLOVA, EasyOCR, PaddleOCR)에 이 이미지들을 넣어보니, 각각 존재하지 않는 글리프의 77–83%를 유효 음절 하나로 바꿔 읽었다. 게다가 두 엔진이 동시에 답을 낸 경우의 77%는 **서로 다른 글자로** 읽었는데, 이는 원인이 사전에 공유해서가 아니라 폐쇄형 구조 그 자체에 있음을 시사한다.

이것이 벤치마크 수치에 미치는 영향은 작지 않다. 사람이 매긴 정답과 비교하면 OCR 단독 채점은 절대 정확도를 25.6–50.0%p 낮게 잡는데, 이 과소평가 폭이 철자 복잡도에 따라 커지다 보니 **복합 중성 페널티가 2.3배–4.0배까지 부풀려진다**. 효과크기 추정치가 어떤 OCR 엔진을 쓰느냐에 따라 달라지므로, 서로 다른 엔진을 쓴 논문끼리는 결과를 직접 비교할 수 없다.

특정 생성 모델의 영향을 배제하고 판정자의 성질만 따로 떼어보기 위해, 생성 모델을 아예 쓰지 않는 통제된 대응 표본 실험도 진행했다. 깨끗한 폰트 렌더링(대조군)과, 같은 글자에 프로그램으로 획을 추가하거나 제거한 것(실험군, 구성상 무효)을 비교하는 방식이다. EasyOCR의 답변율은 두 조건에서 통계적으로 구분되지 않았고(96.4% vs 93.0%, $p=0.234$, $\pm 10\%$ p 동등성 검정 통과), confidence 분포도 마찬가지로 비슷했다(0.458 vs 0.464, Mann-Whitney $p=0.841$). 엔진은 진짜 글자와 조작된 글자를 구분하지 못할 뿐 아니라, confidence 값 자체가 그 구분에 대해 아무 정보도 주지 않는다.

여기서 나오는 결론은 "더 정확한 OCR이 필요하다"가 **아니다**. 은폐율은 정확도와 따로 논다 — 세 엔진 중 가장 정확한 것도 78.5%를 은폐한다. 문제는 인식 품질이 아니라 폐쇄형 출력 구조 자체에 있기 때문이다. 필요한 것은 그 한계를 처음부터 전제로 깔고 설계된 평가 프로토콜이다. "유효 문자 아님"을 별도의 결과로 보고하고, 그로 인해 필요해지는 사람 개입 비율을 숨기지 않고 그대로 밝히는 것이다.

사람이 라벨링한 골드셋, 전체 코드, 이 노트의 모든 수치를 원본에서 다시 계산해주는 검증 스크립트를 함께 공개한다.

1. 문제

이미지 생성 모델의 텍스트 렌더링 품질을 재는 벤치마크(AnyText, Qwen-Image의 평가 세트, 그 밖의 한글 특화 시도들)는 대부분 같은 파이프라인을 쓴다. 모델에게 목표 문자열을 프롬프트로 주고, 출력에 OCR을 돌린 뒤, 그 판독 값을 목표와 비교하는 방식이다. 이때 OCR 엔진은 투명한 측정 도구처럼 취급된다.

하지만 실제로는 그렇지 않다. 특정 문자 체계를 인식하도록 학습된 OCR 엔진은 출력 가능한 문자 집합이 고정돼 있다 — 한글이라면 유니코드 한글 음절 블록의 11,172개 완성형이 전부다. 그 집합 밖에 있는 글리프를 만나면 엔진에는 "해당 없음"이라고 답할 방법이 없다. 그저 가장 가까운 후보를 돌려줄 뿐이다.

이게 중요한 이유는, 생성 모델이 실제로 이런 식으로 실패하기 때문이다. 모델은 단순히 **틀린** 글자를 그리는 게 아니라 **존재하지 않는** 글자를 그린다. 실제 감사 과정에서 나온 사례 하나를 보자 — '감(gam)'을 그려달라고 했는데, 모델은 종성 ㅁ 안에 십자획이 들어간 글리프를 만들어냈다. 이건 한글 자모가 아니라 '田'에 가깝다. 사람 감사자는 이를 "입력 불가능"으로 분류했지만, CLOVA와 형태 매칭 대조군은 둘 다 이를 '감'으로 읽고 정답 처리했다.

그림 1은 실제로 생성된 이 쌍을 그대로 보여준다. 제공사와 모델 식별자는 재배포 조건에 대한 서면 확인을 받기 전까지는 밝히지 않는다(\$9). 두 이미지 모두 같은 생성 모델이 같은 프롬프트 템플릿-같은 타깃 음절('감')로 만든 것이고, 다른 건 샘플링 결과뿐이다.




그림 1. 왼쪽은 같은 타깃에 대해 올바르게 조합된 출력이고, 오른쪽은 실제로 관찰된 실패다 — 종성 자리에 '田'과 닮은 무효 글리프가 들어갔다. 생성 모델은 제공사 확인 전까지 비공개로 둔다(\$9). \$5의 인과 실험에 쓰는 통제된 재현은 이 이미지와 무관하게 OFL 폰트 렌더링만으로 이뤄진다(그림 2).

지배적인 실패 유형이 측정 도구의 눈에 아예 안 보인다면, 그 벤치마크는 자기가 쟁다고 주장하는 것과 다른 무언가를 재고 있는 셈이다.

2. 데이터

생성 모델. 유료 API로 접근한 상용 텍스트-이미지 생성 모델로 300장을 만들었다. 프롬프트 템플릿 2종, 단일 한글 음절 타깃을 18셀 층화 설계(모음 2분류 × 종성 3분류 × 초성 3분류 — docs/partitioning.md 참고)에 따라 골랐다. 제공사와 모델 식별자는 재배포-공표 조건을 서면으로 확인받기 전까지 이 노트 본문에는 적지 않는다 (docs/RELEASE.md 참고). 이는 발견을 감추려는 게 아니라 공개 범위를 신중하게 잡은 것이며, 특정 모델을 지목해 평가하려는 것도 아니다 — §7에서 이 노트가 어떤 모델도 순위 매기거나 특성화하지 않는다고 밝힌다.

사람 정답. 300장 전부를 target-blind로 라벨링했다. 파일럿 단계에서 "판독 가능/불가능"이라는 1차 기준이 감사자마다 다르게 적용되는 걸 발견한 뒤, 기준을 다음과 같이 못박았다:

이 글리프를 표준 키보드로 입력할 수 있는가? (같은 말로: 11,172개 완성형 음절 중 하나인가?)

이건 주관적인 판독성 판단이 아니라 이진적이고, 검증 가능하고, 재현 가능한 기준이다. 감사자는 유효하다고 판단한 경우에만 전사를 남겼다.

신뢰도. 감사자 두 명이 87문항짜리 부분집합을 독립적으로 라벨링했다.

판정	일치도
이진 유효성(유효/무효)	97.7% raw · Krippendorff's $\alpha = 0.942$
둘 다 유효라 한 경우의 전사	23/23 = 100%
4분류 세부(malformed/non-Hangul/multi/none)	$\alpha = 0.576$

이진 측은 아주 신뢰할 만하고, 그 뒤에 나오는 전사는 완벽하게 일치한다. 반면 세부 분류는 **믿을 수 없다** — "malformed 한글"과 "한글 아님"의 경계는 딱 잘라지지 않는 연속체이고, 불일치 21건 중 17건이 정확히 이 경계에 서 나왔다. 그래서 1차 지표로는 이진 판정만 쓰고, 세부 분류는 exploratory 자료로만 남긴다.

라벨 분포(n = 300).

라벨	n	비율
유효 음절	235	78.3%
malformed(한글 구조지만 획이 무효)	42	14.0%
non-Hangul(기호, 도형)	13	4.3%
다중 음절	10	3.3%
유효 음절 아님(합계)	65	21.7%

3. 결과 1 — 세 엔진이 같은 비율로 무효 글리프를 은폐한다

사람이 무효로 판정한 65장 하나하나에 대해 물었다. 그래도 엔진이 유효한 한글 음절 하나를 돌려주는가?

엔진	아키텍처	은폐율	위양성(타깃과 일치)
CLOVA General OCR	상용, 폐쇄형	50/65 = 76.9%	2
EasyOCR	CRNN, 오픈소스	54/65 = 83.1%	3
PaddleOCR(korean_PP-OCrv5)	PP-OCR, 오픈소스	51/65 = 78.5%	3

세 엔진은 학습 데이터도 아키텍처도 공유하지 않는데, 결과는 77-83%로 비슷하게 수렴한다.

원인은 공유된 사전이 아니라 폐쇄형 구조 그 자체다. CLOVA와 EasyOCR 둘 다 답을 낸 무효 이미지 44건 중 **34건 (77.3%)이 서로 다른 글자로 읽혔다.** 두 엔진은 "이게 무슨 글자인지"에는 동의하지 않고, "어쨌든 뭐라도 있다"라는 것에만 동의하는 셈이다.

예시(타깃 → CLOVA / EasyOCR): **뽕** → **꽤** / **팩** · **췌** → **췌** / **췌** · **췌** → **췌** / **췌** · **췌** → **췌** / **췌**.



target: 팍

CLOVA reads: 풀

EasyOCR reads: 팔

그림 3. 타깃 '팍'은 ㅍ + ㅊ(ㅊ와 ㅊ 두 획으로 이뤄진 복합모음) + ㅅ(ㄱ과 ㅅ이 겹친 종성)으로 구성된다. 그런데 실제로 그려진 글리프는 초성 ㅍ 다음에 서로 분리된 모음 획 두 개를 붙여놓은 모양이다 — 하나는 ㅊ처럼 생겼고, 다른 하나는 빼침이 두 개라 ㅊ에 가깝다. 이 조합(ㅊ + ㅊ)은 한글의 이중모음 일곱 개(ㅊㅅ, ㅊㅈ, ㅊㅊ, ㅊㅌ, ㅊㄹ, ㅊㅍ, ㅊㅑ) 어디에도 없다 — 애초에 존재하지 않는 모음 조합이다. 종성도 목표한 겹받침 대신 단순 ㅅ 하나로 단순화됐다. 이렇게 그려진 두 모음 획을 동시에 담는 유효 음절은 존재하지 않으므로, CLOVA와 EasyOCR은 각자 하나씩만 골라 쓴다 — CLOVA는 ㅊ 모양 획에 맞춰 '풀'(ㅍ+ㅊ+ㅅ)로, EasyOCR은 ㅊ 모양 획과 가장 가까운 단일모음인 ㅊ에 맞춰 '팔'(ㅍ+ㅊ+ㅅ)로 읽는다. 두 엔진은 모호한 모음 하나를 놓고 의견이 갈린 게 아니다 — 애초에 유효한 답이 없는 글리프에서, 각자 실제로 그려진 획 중 다른 쪽을 버린 것이다.

위양성 — 은폐된 판독이 우연히 타깃과 맞아떨어져 점수를 직접 부풀리는 경우 — 은 드물다(65건 중 2~3건). 은폐가 측정을 망가뜨리는 주된 경로는 점수를 부당하게 주는 게 아니라 **실패 범주 자체를 지워버리는** 데 있다.

4. 결과 2 — 과소평가가 복잡도에 따라 커지고, 구조적 효과를 과장한다

타깃 대비 완전일치 정확도(unconditional, 무효는 오답 처리), n=300:

종성유형	사람	CLOVA	EasyOCR	PaddleOCR
무종성	70.0%	44.4%	43.3%	61.1%

단순중성	60.8%	30.0%	17.5%	27.5%
검받침	55.6%	8.9%	5.6%	10.0%
전체	62.0%	28.0%	21.7%	32.3%

과소평가 폭(사람 - 엔진), 쌍대응 bootstrap, 95% CI:

	무중성	단순중성	검받침
CLOVA	+25.6 [15.6, 35.6]	+30.8 [22.5, 39.2]	+46.7 [36.7, 57.8]
EasyOCR	+26.7 [16.7, 36.7]	+43.3 [34.2, 52.5]	+50.0 [38.9, 61.1]
PaddleOCR	+8.9 [1.1, 17.8]	+33.3 [25.0, 41.7]	+45.6 [34.4, 56.7]

세 축 전부 신뢰구간이 0을 포함하지 않는다. 결정적인 건 **과소평가 폭이 일정하지 않다**는 점이다 — 철자가 복잡할 수록 폭도 커진다. 구조적 비교는 결국 두 정확도의 차이인데, 이렇게 복잡도와 함께 커지는 편향은 서로 상쇄되지 않고 그대로 남는다.

	검받침 - 단순중성 격차	과장	배율
사람(진실)	-5.3%p	—	1.0×
CLOVA	-21.1%p	-15.8%p, CI [-29.4, -1.4] 유의	4.0×
PaddleOCR	-17.5%p	-12.2%p, CI [-25.3, +1.7] 비유의	3.3×
EasyOCR	-11.9%p	-6.7%p, CI [-21.1, +7.8] 비유의	2.3×

세 엔진 모두 검받침 패널티를 실제보다 크게 잡으며, CLOVA는 n=300 기준으로 통계적으로 유의하다. **과장 배율이 엔진마다 다르므로** (2.3배-4.0배), 서로 다른 OCR 엔진을 쓴 연구들끼리는 효과크기를 비교할 수 없다.

이것이 이 노트에서 실용적으로 가장 중요한 주장이다. "복잡한 철자 구조가 렌더링 품질을 X% 떨어뜨린다"고 OCR 채점으로 결론 낸 논문이 있다면, 그 숫자는 실제 효과의 몇 배일 수 있고, 그 배율은 순전히 어떤 채점 도구를 골랐느냐에 좌우된다.

5. 결과 3 — 통제 실험: 엔진은 조작된 글리프를 탐지하지 못한다

앞선 결과 1, 2는 관찰 연구다 — 한 생성 모델의 출력을 놓고 판정자를 사람 라벨과 대조했을 뿐이다. 판정자의 성질을 특정 생성 모델과 무관하게 인과적으로 확인하려면 별도 실험이 필요했다. 그래서 **생성 모델을 전혀 쓰지 않는** 대응표본 실험을 설계했다.

설계.

대조군	유효 음절의 깨끗한 폰트 렌더링(n=84)
실험군	같은 음절에 획을 프로그램으로 추가·삭제, 3단계 심각도(n=497)
무작위화	음절·조작 위치·심각도 모두 seed 기반 난수로 결정
통제	폰트·해상도·글자 크기·잉크량 — 같은 원본 글자를 그대로 사용

정답	구성상 무효; 우연히 다른 진짜 글자를 재구성한 표본(7건)은 template-match 사후검증으로 걸러 제외
----	--

조작 방식은 사람 감사 메모에 실제로 기록된 실패 유형("중성 ㅂ의 획 하나 누락", "ㅡ에 알 수 없는 획 추가")을 일 반화한 것이다.



그림 2. 대응표본 설계의 다섯 조건 전부에 걸쳐 같은 음절(값)을 보여준다. `synthetic_malformed.make_item()` 으 로 생성한 뒤, 다섯 패널 전부에 같은 seed로 같은 인쇄물풍 열화를 입혀서 비교가 렌더링 잡음이 아니라 조작 그 자체만 반영하도록 했다. 맨 왼쪽만 진짜 음절이고 나머지 넷은 구성상 무효다. mild에서 severe로 갈수록 획 개수와 변위가 커지는 걸 볼 수 있다.

결과(EasyOCR).

	대조군	실험군
유효 음절로 답함	96.4%	93.0%
평균 confidence	0.458	0.464

- 답변율 차이는 -3.5% , $z=-1.19$, $p=0.234$ 로 유의하지 않다. 다만 여기서 확인하려는 가설은 "구분하지 못 한다"는 부재 가설이라, 단순히 기각에 실패했다고 끝내지 않고 $\pm 10\%$ p margin의 TOST 동등성 검정을 추 가로 돌렸다. 95% CI $[-9.2, +2.2]$ 가 margin 안에 완전히 들어오므로, 동등성이 적극적으로 입증된 셈이다.
- confidence는 Mann-Whitney 검정에서 $p=0.841$ 이 나왔다. 진짜 글자를 볼 때의 confidence 분포와 조작된 글자를 볼 때의 분포가 통계적으로 같다는 뜻이다. 이 구분에 대해 confidence는 아무 신호도 주지 않는다 — confidence 임계값으로 걸러내려는 뻔한 해법이 왜 안 통하는지 여기서 드러난다.

결과(template matching, 폐쇄형 형태 대조군). 대조군 정확도는 96.4%였고, 조작된 글리프에서도 94.0%의 비율로 원본으로 스냅했다. 언어 모델을 전혀 쓰지 않는 순수 기하학적 매칭기조차 같은 행동을 보인다는 건, 기전이 언어적 사전지식이 아니라 폐쇄형 강제선택 자체에 있다는 뜻이다.

민감도. 그렇다고 엔진이 완전히 무감각한 건 아니다 — 획을 삭제했을 때 스냅률이 98.8%(약함)에서 81.0%(심함)로 떨어진다 ($p=0.0002$). 탐지는 정도의 문제인 셈이다. 다만 획 하나 정도의 근소한 오차 구간이 바로 탐지가 실패하는 지점이고, 실제 생성 모델의 실패도 대부분 그 구간에 몰려 있다.

3번째 엔진(PaddleOCR)은 규모를 줄여($n=126$) 다시 실험했는데, 방향은 그대로 재현됐지만(대조군 88.9% vs 실험군 84.3%, $p=0.611$; confidence 0.669 vs 0.591, $p=0.351$) 대조군이 $n=18$ 로 작아서 엄격한 동등성 검정은 통과하지 못 했다. 그래서 확정 결과로는 EasyOCR(대조군 $n=84$)을 내세우고, PaddleOCR은 방향성을 재확인하는 보조 증거로만 덧붙인다.

6. 부분적 완화책과 그 한계

confidence 게이트로 자동 채점을 구제할 수 있는지도 시험해봤다 — confidence가 0.80 이상이면 OCR 판독을 그대로 채택하고, 나머지는 사람에게 넘기는 방식이다. 실측 결과 두 가지를 보정해야 했다.

- 게이트는 **중성 측에서는 스스로 교정된다**. CLOVA는 정확히 믿을 수 없는 지점에서 confidence를 잃기 때문에, 어려운 사례가 사람에게 넘어가면서 편향이 오히려 줄어든다.
- 반대로 **쌍자음 초성(ㄲ ㅋ ㆁ ㄷ ㅌ ㅍ ㅈ ㅊ ㅍ ㅍ)**에서는 **이 자기교정이 실패한다**. CLOVA가 여기서는 *자신 있게* 틀린다. 자동 채택 구간에서 사람과의 불일치율이 47.4%나 되는데, 기본 초성은 4.5%에 불과하다. 쌍자음 초성을 자동 채택에서 제외하면 18셀 세 축 모두에서 편향 변동폭이 2.5%p 아래로 떨어진다.

결과로 나온 프로토콜에서도 **이미지의 50%는 여전히 사람 판정이 필요하다**. 이걸 해법의 미완성으로 보지 않고, 이 작업에서 실측으로 확인된 자동화의 하한으로 보고한다. 더 중요한 건, 이 프로토콜조차 무효 글리프를 탐지하지 못한다는 점이다 — 자동 채택된 128건 중 16건(12.5%)이 사람 기준으로는 무효인데도 유효로 부풀려져 보고된다. **이 프로젝트가 발견한 은폐 현상이 우리 자신의 결과표 안에서도 그대로 재현된 셈**이며, 그래서 자동으로 채점된 수치는 반드시 실측 편향과 함께 보고해야 한다.

7. 이 노트가 주장하는 것과 주장하지 않는 것

주장하는 것.

1. 인식 기반 판정자는 존재하지 않는 글리프를 77–83% 비율로 은폐하며, 이는 서로 독립적인 아키텍처 세 개에서 똑같이 재현된다(\$3).
2. OCR 단독 채점은 정확도를 25.6–50.0%p 낮게 잡고, 그 폭이 복잡도에 따라 커지면서 구조적 효과를 2.3배–4.0배 부풀린다(\$4).
3. 엔진은 조작된 글리프와 진짜 글리프를 구분하지 못하며, confidence도 그 구분에 대해 아무 신호를 주지 않는다 — 생성 모델 없이 통제된 대응표본 실험으로 인과적으로 확인했다(\$5).
4. 사람의 이진 유효성 판정은 신뢰할 만하고($\alpha=0.942$), 전사가 필요 없어서 가장 저렴한 사람 판정이기도 하다.

명시적으로 주장하지 않는 것.

- **모델 벤치마크가 아니다**. 생성 모델은 1종, 이미지는 300장뿐이다. 이 모델이든 다른 어떤 모델이든 순위를 매기려는 게 아니다. 생성 모델은 이 노트의 주제가 아니라 사례일 뿐이다.
- **철자 구조에 대한 인과 주장이 아니다**. 겹받침이 더 어렵다는 발견은 관찰 연구에서 나온 것이라 음절 빈도, 획수와 뒤섞여 있고, 이 둘을 분리하지는 못했다. 실제로 이 프로젝트의 초기 버전에서는 이 교란변수를 찾아내기 전에 OCR 크기 관련 문제를 중성 복잡도 탓으로 잘못 돌린 적도 있다.
- **셀 단위(18셀) 값은 보고하지 않는다**. 셀당 이미지가 12장 정도라 신뢰구간을 낼 수 있는 규모가 아니다. 그래서 세 개의 주변 축만 보고한다.
- **§8.2에서 다른 문자 체계로 일반화한 부분은 예측이지 확인된 결과가 아니다**. 실제로 시험한 건 한글뿐이다. 중국어·일본어·데바나가리. 아랍어 데이터는 수집하지 않았고, §8.2는 기전에 근거한 예상과 그걸 검증할 방법을 제시하는 데 그친다.
- **§8.1에서 말하는 탈동조 현상은 엔진 세 개에 근거한 관찰이다**. 은폐율이 정확도를 따라가지 않는다는 것만 주장하며, 둘이 반비례 관계라고 주장하지는 않는다.
- **쌍자음 초성 제외 규칙은 in-sample 결과다**. $n=63$ 에서 뽑아내 같은 데이터로 검증했기 때문에, out-of-sample 재검증이 필요하다.
- **주 감사자 한 명은 저자 본인이다**. 두 번째 감사자는 독립적으로 참여했고, 일치도 통계는 이 둘 사이에서 계산했다. 이는 한계이며 그대로 밝혀둔다.

8. 합의

8.1 해법은 "더 정확한 OCR"이 아니다

이 결과만 보면 더 나은 OCR 엔진을 쓰면 되지 않겠냐는 결론으로 흐르기 쉽다. 그런데 데이터는 정반대를 가리킨다 — **은폐율은 정확도와 따로 논다**.

엔진	정확도(유효 글자)	은폐율(무효 글자)
PaddleOCR	32.3% (최고)	78.5%
CLOVA	28.0%	76.9% (최저)
EasyOCR	21.7% (최저)	83.1% (최고)

세 엔진의 정확도는 최대 1.49배까지 차이가 나지만, 은폐율 차이는 1.08배에 그친다. **가장 정확한 엔진조차 존재하지 않는 글리프의 78.5%를 은폐한다.** (엔진이 3개뿐이라 순위가 딱 뒤집힌다는 식의 단조 관계까지 주장하지는 않는다. 은폐율이 정확도를 따라가지 않는다는 것만 확인된 사실이다.)

이건 기전을 생각하면 오히려 당연한 결과다. 은폐는 학습을 더 시킨다고 없어지는 인식 오류가 아니라 **출력 형식 자체의 귀결**이다. 라벨 공간이 유효 음절 11,172개뿐인 분류기에는 "이 중에 없음"에 해당하는 기호가 아예 없다. 그러니 "이게 애초에 문자이긴 한가"라는 질문은 잘못 답해지는 게 아니라, 애초에 **몰어질 수조차 없다**. §5에서 확인한 것도 결국 같은 얘기다 — 조작된 글리프의 confidence 분포가 진짜 글자와 통계적으로 똑같으니($p=0.841$), 사후에 confidence 임계값을 아무리 조정해도 이 구분을 되살릴 수 없다.

라벨 공간을 개방형으로 만드는 것 — open-set recognition이나 잘 보정된 reject option 같은 것 — 은 한국어 학습 데이터를 더 모은다고 풀리는 문제가 아니라 머신러닝 전반의 미해결 난제다. **"더 좋은 OCR을 구하자"를 다음 할 일로 삼는 건 문제 해결을 무기한 미루는 것과 같다.** 현실적으로 갈 수 있는 방향은 이 한계를 처음부터 전제로 깔고 **평가 프로토콜**을 설계하는 것이고, §6과 §8.3에서 그 얘기를 이어간다.

8.2 한글을 넘어서 — 다른 조합형 문자 체계에 대한 예측

한글은 조합 규칙이 명시적이고 유효 문자 집합을 정확히 셀 수 있어서 ($19 \times 21 \times 28 = 11,172$) 시험대로 삼기 좋은 문자 체계다. "이 글리프는 그 집합에 없다"는 판정을 내리고 검증할 수 있는 것도 그래서다. 하지만 지금까지 확인한 기전 자체는 한글에만 있는 성질이 아니다.

그래서 여기서 직접 확인하지는 않았지만 다음과 같이 예측한다 — 재사용 가능한 부품을 조합해서 문자를 만들고, 인식기의 라벨 공간이 그렇게 조합된 문자들의 집합인 문자 체계라면 어디서든 같은 은폐가 일어날 것이다. 중국어의 부수 조합, 일본어 한자, 데바나가리를 비롯한 브라흐미계 결합 문자, 아랍어 합자 형태가 모두 여기 해당한다. 이런 문자 체계에서 생성 모델이 그럴듯하지만 실재하지 않는 조합을 그린다면, 여기서와 똑같은 이유로 가장 가까운 실제 문자에 조용히 매핑될 것이다.

이게 중요한 이유는, 주요 시각 텍스트 렌더링 벤치마크(AnyText, Qwen-Image 평가 세트 및 그 후속 연구들)가 여기서 시험한 것과 같은 계열의 OCR 파이프라인으로 중국어를 채점하고 있기 때문이다.

이 예측은 검증 비용이 크지 않고, 검증에 필요한 수단도 함께 공개한다 — §5의 `synthetic_malformed` 절차는 폰트 하나와 유효 문자 목록만 있으면 되고, 생성 모델도 필요 없으며, 정답이 구성 단계에서부터 보장된다. 다른 문자 체계로 옮기려면 문자 집합과 조작 방식만 바꿔 끼우면 된다.

8.3 권고

시각 텍스트 렌더링 벤치마크를 만들거나 읽는 사람에게 제안한다.

- 모델을 채점하기 전에 판정자부터 검증하라.** 같은 분포에서 뽑은 표본으로 판정자를 사람 라벨과 대조해보라. 이 프로젝트도 파이프라인을 점검하기 전까지 세 번이나 잘못된 원인 진단을 내렸다 — OCR 글꼴 크기 문제를 모델의 약점으로 잘못 돌린 것도 그중 하나다.
- 정확도뿐 아니라 판정자가 기권(abstain)할 수 있는지도 시험하라.** 유효한 문자에 대한 정확도는 무효한 문자를 만났을 때의 행동에 대해 아무것도 말해주지 않는데, 생성 모델은 바로 그 지점에서 실패한다. §8.1에서 봤듯 가장 정확한 엔진을 고른다고 해결되는 문제가 아니다.
- "유효 문자 아님"을 "틀린 문자"와는 별개의 1급 결과로 보고하라.** 원인이 다른 별개의 실패이고, 결과표에 항목 하나 추가하는 데 드는 비용은 사실상 없다.

- 서로 다른 OCR 엔진을 쓴 연구끼리 효과크기를 비교하지 마라. 과장 배율이 엔진마다 다르다(여기서는 2.3배→4.0배).
- 완전 자동화가 안 된다면 그렇다고 밝히고 사람이 개입하는 비율을 정량화하라. 그걸 숨긴 자동화 수치를 내놓지 마라. 이 작업에서 실측한 하한은 50%이고, 이를 미달로 보지 않고 하나의 결과로 보고한다.

9. 재현성

이 노트의 모든 수치는 다음 명령으로 원본 데이터에서 다시 계산된다.

```
python scripts/verify_claims.py
```

스크립트 출력이 이 문서와 다르면 문서 쪽이 틀린 것이다. 이런 스크립트를 따로 둔 이유가 있다 — 예전 버전에서 데이터 로딩 버그 때문에 사람이 라벨링한 이미지 44장이 조용히 빠지면서, 이 프로젝트의 결론 두 개가 뒤집힌 적이 있었다. 그 뒤로는 수치를 손으로 옮겨 적지 않는다.

공개 산출물, 코드 구조, 라이선스는 [docs/RELEASE.md](#)에 정리돼 있다.

환경 참고. PaddleOCR 3.x는 Windows CPU 환경에서 `enable_mkldnn=False`를 켜야 한다(기본값으로 두면 PIR/oneDNN 오류로 죽는다). OpenCV는 Windows에서 한글이 포함된 경로를 못 읽기 때문에, 이미지 로딩은 전부 PIL을 거친다.

10. 저자 표기와 도구 사용 공개

연구 설계, 데이터 수집, 라벨링, 통계 분석, 그리고 이 노트의 모든 결론은 저자 본인의 작업이며,

`verify_claims.py` (§9)를 실행하면 원본 데이터에서 독립적으로 재확인할 수 있다 — 재계산 스크립트 없이 주장되는 수치는 이 문서에 없다. 문장 초안 작성, 편집, 그리고 이 한글 번역은 범용 AI 글쓰기 도구의 도움을 받아 저자의 지시 아래 작성했으며, 모든 주장과 그림은 저자가 검토했고 그 정확성에 대한 책임을 진다. 이 저작물에 AI 시스템은 저자로 표기되지 않으며, 실제 데이터에 없는 결과를 암시하기 위해 생성된 텍스트나 그림도 없다.

그림 두 장(그림 1, 그림 3)은 연구 대상인 상용 텍스트-이미지 모델의 실제 출력물을 담고 있다. 이는 이 노트를 위해 만든 편집용 콘텐츠가 아니라 측정 대상 자체인 **실험 데이터**이며 — 논증을 꾸미기 위해 생성한 삽화가 아니라 측정하고 있는 그 대상이라는 뜻이다 — 각 캡션에 그 사실을 명시했다(§1, §3).

부록 A — 실패 구성비(사람 정답 기준, n = 300)

종성유형	정답	유효하지만 오답	유효 문자 아님
무종성(n=90)	70.0%	13.3%	16.7%
단순종성(n=120)	60.8%	15.0%	24.2%
겹받침(n=90)	55.6%	21.1%	23.3%

종성유형별 유효 음절 생성률(부트스트랩 CI):

종성유형	비율	95% CI
무종성	83.3%	[75.6, 90.0]
단순종성	75.8%	[67.5, 83.3]
겹받침	76.7%	[67.8, 85.6]

겹받침과 무중성의 차이는 -6.7%p, CI [-17.8, +4.4]로 **유의하지 않고**, 단조 관계도 아니다. 겹받침이라서 무효 글리프가 더 많이 나온다고 주장하지는 않는다.

부록 B — 자모 위치별 오류율(사람 정답 기준)

위치	Conditional(유효만, n=235)	Unconditional(무효=3위치 전부 오류, n=300)
초성	1.7% [0.4, 3.4]	23.0% [18.3, 28.0]
중성	9.8% [6.0, 13.6]	29.3% [24.3, 34.3]
종성	17.0% [12.3, 21.7]	35.0% [29.7, 40.3]

초성 < 중성 < 종성 순서는 두 분모 어느 쪽으로 계산해도 유지된다. 다만 자모 분해는 유효 음절에만 정의된다는 점은 짚어둘 필요가 있다 — 무효 글리프의 분해값은 판정자가 무엇으로 스냅했든 그에 따른 부산물일 뿐이라, 두 분모를 항상 함께 보고한다.